

Probabilistic Graphical Models

Alfredo Rossi Saldanha Cunha
Peng Yaohao

Laboratório de Aprendizado de Máquina em Finanças e Organizações

Level 3: Master



Expectations: You'll be able to construct probabilistic models for novel problems, determine a reasonable inference technique, and evaluate your methodology. You'll also have a much deeper understanding of how various models relate, e.g. how **deep belief networks** can be viewed as **factor graphs** [§](#).

Definição

Modelo gráfico probabilístico (PGM)

É um modelo probabilístico no qual um **grafo** indica a dependência condicional entre variáveis aleatórias

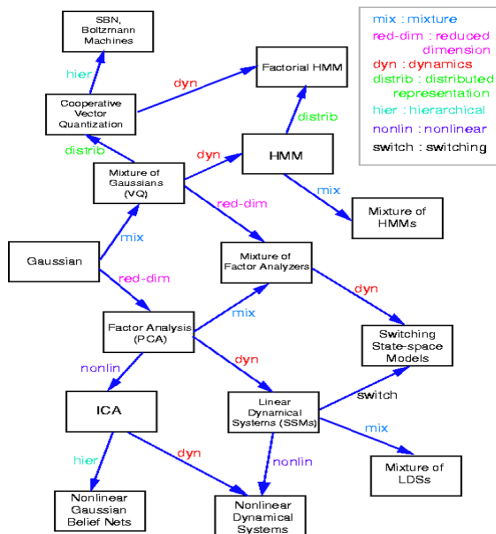
- **Grafo**: Estrutura que representa relações entre objetos com vértices e arestas

PGMs: Visão geral

PGMs englobam uma grande variedade de modelos de estatística e *machine learning*, tais como:

- Cadeias de Markov
- Markov oculto
- Análise fatorial
- Máquinas de Boltzmann
- Redes neurais artificiais

PGMs: Visão geral



Crash Course de teoria dos grafos em 5 minutos...



<https://people.revoledu.com/kardi/tutorial/GraphTheory/vertex.html>

O que é um grafo?

Grafos são estruturas que “contam uma história de pontos e linhas”:

- Vértices (“nós”): **coisas**
- Arestas: **relações entre as coisas**

Um grafo pode representar:

- Teclado do computador
- Árvore genealógica
- Mapa-mundi
- Fluxos migratórios
- Estrutura atômica
- ...

Grafos sem arestas são chamados de “grafos vazios”

Conexões entre nós

Nós conectados por arestas são ditos *adjacentes* (“vizinhos”)

- Uma aresta não pode conectar mais de dois nós
- Uma aresta que conecta um nó a ele mesmo é um *loop*
- Dois nós podem ser conectados por mais de uma aresta

Um grafo sem *loops* e sem arestas múltiplas é dito ser um ***grafo simples***

Grau de um nó

O grau (“valência”) de um nó é o número de arestas que passa por ele

- Cada aresta contribui com 2 ao(s) grau(s) de seus destinos
- A soma dos graus de todos os nós = $2 * \text{número de arestas}$
[“Lema do aperto de mãos”]
- Um grafo **regular** possui todos os nós com o mesmo grau


Exercício



- Quantos nós possui um grafo regular de grau 3 que tem 6 arestas?
- É possível construir um grafo regular de grau 2 com um número arbitrariamente grande de arestas?



Grafos completos

Um grafo é dito ser **completo** se todos os pares de nós forem conectados por uma aresta



Grafos direcionados e ponderados



- Grafos direcionados indicam a ordem da relação entre os nós
- Grafos ponderados possuem um valor associado a cada aresta



Grafos cíclicos

Ciclo é um caminho que começa e termina com o mesmo nó

- Um grafo **cíclico** apresenta pelo menos um *ciclo simples* (com pelo menos 3 nós, percorrendo todos os nós exceto o inicial/final apenas uma vez)



Grafos cíclicos



Bayesian Networks

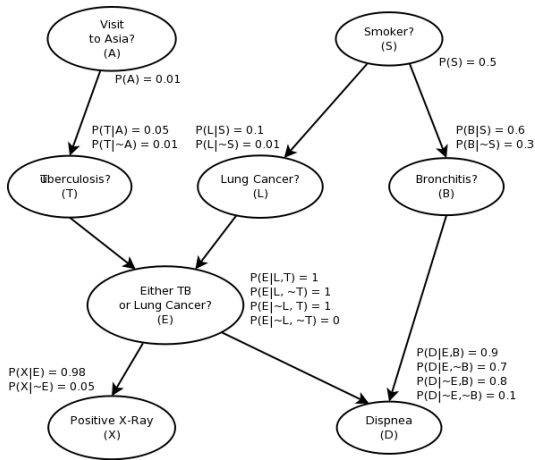
Bayesian Networks apresentam um **grafo direcionado acíclico**, no qual a distribuição conjunta das variáveis aleatórias pode ser expressa pelo produto de distribuições condicionais:

$$P[X_1, \dots, X_n] = \prod_{i=1}^n P[X_i | \Xi_i]$$

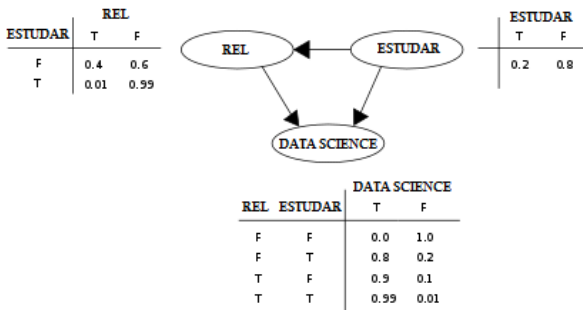
Onde Ξ_i é o conjunto de nós-parente do nó X_i

- Condicionados aos valores de seus respectivos nós-parentes, quaisquer dois nós do grafo são condicionalmente independentes
- Diminui o número de estimações da distribuição conjunta pelas condicionais e marginais

Modelos gráficos e causalidade



Modelos gráficos e causalidade

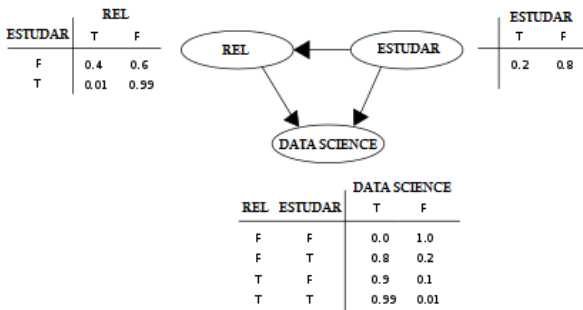


- Probabilidade conjunta:

$$P(D, R, E) = P(D|R, E)P(R|E)P(E)$$

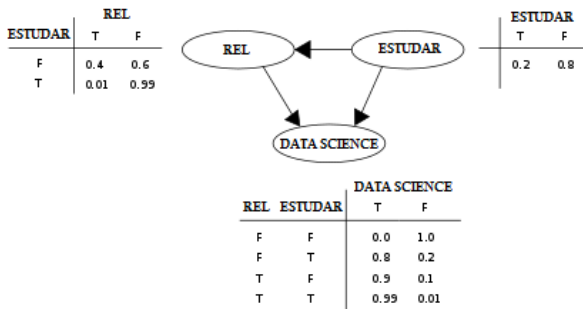
- Pergunta observacional: $P(E|D) = \frac{P(D|E)P(E)}{P(D)}$

Modelos gráficos e causalidade



- Pergunta de ação: $P(R, E|do(D)) = P(R|E)P(E)$
- $P(E, D|do(R = T)) = P(D|E, R = T)P(E)$

Modelos gráficos e causalidade



- Contrafactual: $P(D|R_{\oplus} \Leftrightarrow)$

Markov Networks

Markov Networks apresentam um **grafo não-direcionado** (cíclico ou não), no qual:

- Quaisquer duas variáveis aleatórias são condicionalmente independentes, dadas todas as outras variáveis:

$$X_u \perp\!\!\!\perp X_v \mid X_{V \setminus \{u,v\}}$$

- Uma variável aleatória é condicionalmente independente a todas as outras dada sua vizinhança fechada:

$$X_v \perp\!\!\!\perp X_{V \setminus N[v]} \mid X_{N(v)}$$


- Quaisquer dois conjuntos de variáveis aleatórias são condicionalmente independentes dado um conjunto separador:

$$X_A \perp\!\!\!\perp X_B \mid X_S$$

Máquinas de Boltzmann

Modelo não-supervisionado com grafo completo que atribui probabilidades a estados entre unidades visíveis e unidades ocultas


- A distribuição de Boltzmann modela a probabilidade de ocorrência de um estado num sistema físico em função da energia e da temperatura



- Extrai características mais relevantes de um fenômeno (“estados mais estáveis”)
- Inviáveis de treinar na prática

Máquinas de Boltzmann Restritas

São máquinas de Boltzmann cuja representação é um grafo bipartido




$$E(\mathbf{h}, \mathbf{x}) = -\mathbf{b} \cdot \mathbf{v} - \mathbf{c} \cdot \mathbf{h} - \mathbf{h}^T \mathbf{W} \mathbf{v}$$

- Treinamento rápido
- Sistemas de recomendação/filtro colaborativo [Prêmio Netflix]
- Constructos latentes formativos?


Deep Belief Network

É um empilhamento de RBMs



- Podem ser treinadas de forma *greedy*
- Procedimento eficiente, de camada por camada, para aprender os pesos de cima para baixo, sem necessidade de ter um label

Deep Belief Network



- Reconhecimento de face
- Reconhecimento de vídeo (sequência)
- Imagem de Satélite, NASA

Inferência, Estimação por amostras

- Rejection Sampling
- Importance Sampling
- **Markov Chain Monte Carlo (MCMC)**
 - Metropolis Hastings (MH)
 - Gibbs Sampling

MCMC

- Classe de algoritmos
- Muito utilizada desde a década de 80/90
- Soluciona problema mais complexos de estimação
- Consiste em propor uma distribuição ($q(x)$) e tirar amostras ($q(x_t/x_{t-1})$)
- Vai "descobrimdo" a distribuição aos poucos

MH

- Constroi uma Cadeia de Markov ergótica e estacionária em relação a distribuição original
- Distribuição proposta converge quase certamente para a original
- Algoritmo MH
 - $x_t \rightarrow q(x_t/x_{t-1})$, q é a dist. proposta
 - Calcule a probabilidade de aceitação
$$p(x_t, x_{t-1}) = \min\left(1, \frac{\hat{p}(x_t)q(x_{t-1}/x_t)}{\hat{p}(x_{t-1})q(x_t/x_{t-1})}\right)$$
 - Aceite x_t com probabilidade $p(x_t, x_{t-1})$ e x_{t-1} com probabilidade $1 - p(x_t, x_{t-1})$

Gibbs


- Precisa das distribuições condicionais
- Gerar amostras da posteriori varrendo cada variável para amostrar a partir de sua distribuição condicional com as variáveis restantes fixadas
- Algoritmo Gibbs
 - Inicie o valor da priori $x^{(0)} \leftarrow q(x)$
 - Itere para $i = 1, \dots$
 - $x_1^{(i)} \leftarrow p(X_1 = x_1 / X_2 = x_2^{(i-1)}, \dots, X_D = x_D^{(i-1)})$
 - $x_2^{(i)} \leftarrow p(X_2 = x_2 / X_1 = x_1^{(i)}, X_3 = x_3^{(i-1)}, \dots, X_D = x_D^{(i-1)})$
 - \vdots
 - $x_D^{(i)} \leftarrow p(X_D = x_D / X_1 = x_1^{(i)}, \dots, X_{D-1} = x_{D-1}^{(i)})$

Aplicação no R



Obrigado!

SUMMER



JORGE CHAM © 2018

WWW.PHDCOMICS.COM