

Autoencoder

Fernanda Santos Amorim
Pedro Watuhã

LAMFO/UnB

24 de outubro de 2020



Aprendizado Não-Supervisionado

Modelos Não-Supervisionados, em sua maioria, trabalham sem dados de treinamento e o objetivo é modular uma distribuição que consiga prever os fenômenos, isto é, aprender a estrutura dos dados.



Autoencoder

O *Autoencoder* é um modelo semelhante a redes neurais desenhado para aprendizado não-supervisionado, isto é, os dados de entrada não precisam estar rotulados para este tipo de modelos.

O método possui duas partes um **codificador** e um **decodificador**. O codificador **reduz a dimensionalidade** dos dados de entrada e o decodificador **refaz os dados de entrada** e o objetivo principal do algoritmo é minimizar o erro de reconstrução.



Estrutura de Autoencoder




Figura: Estrutura do Autoencoder

Características do Autoencoder

Autoencoder é um algoritmo de compactação e descompressão de dados e possui as seguintes características:

- *Data-Specific*
- *Lossy*
- “Aprende” a partir de modelos



Arquitetura do Autoencoder

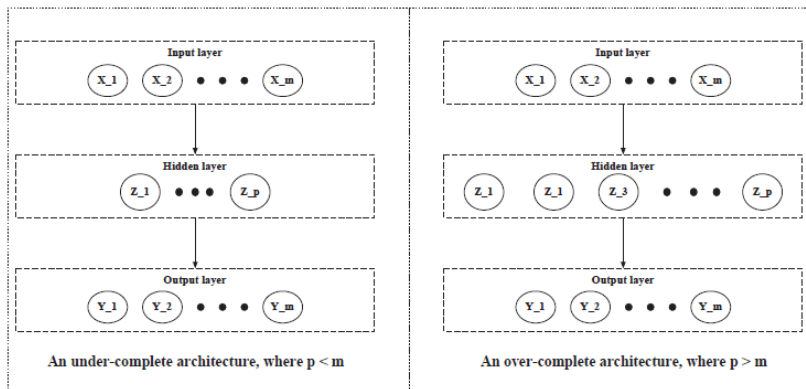


Figura: Arquitetura do Autoencoder

Arquitetura do Autoencoder

Os dados de entrada são representados por X_1, X_2, \dots, X_m e os dados de saída são representados por Y_1, Y_2, \dots, Y_m , ambos os dados possuem as mesmas dimensões n e m . Sendo que, n representa o número de observações da base de dados e m representa o número da variável. O codificador é representado por Z_1, \dots, Z_p , a função do codificador é transformar os dados de entrada e o decodificador reconstrói os dados.



Autoencoder

$$\begin{aligned} Z &= f_{\Theta} = S(\mathbf{W}X + \mathbf{b}) \\ Y' &= f_{\Theta'} = S(\mathbf{W}'Z + \mathbf{b}') \\ &\quad ||X - Y'|| \end{aligned} \tag{1}$$

Sob perspectiva matemática, o codificador mapeia os dados por meio de uma função $Z = f_{\theta}(X) = S(\mathbf{W}X + \mathbf{b})$ em que \mathbf{W} representa a matriz de pesos, \mathbf{b} o vetor de viés e S representa uma função de ativação.

Para o decodificador a lógica é muito similar, para tal o mapeamento é feito com a seguinte função $Y' = f_{\theta'}(Z) = S(\mathbf{W}'Z + \mathbf{b}')$.

$||X - Y'||$ é denominada de função perda que é como é feito o cálculo dos erros de reconstrução.



Aplicações

O método pode ser aplicado para

- Redução de Dimensionalidade
- Autoencoder Esperso
- *Variational Autoencoder*
- Redução de Ruído



Variational Autoencoders - VAE

VAEs utilizam da arquitetura dos autoencoders tradicionais. A diferença principal desta variação de Autoencoder é que o modelo irá aprender uma distribuição baseado em amostras aleatórias do espaço latente.

Isso significa que, VAE usa a inferência variacional para gerar sua aproximação a essa distribuição de entrada e, assim, consegue gerar resultados que têm características semelhantes àsquelas nas quais a rede foi treinada.



Redução de Ruído - Aplicação

A Aplicação selecionada como exemplo de Autoencoder será para Redução de Ruído de Imagem.



Obrigado a todos!
Dúvidas?

